2023 2학기 인공지능시스템 3조 · 1차 과제

유튜브 영상 조회수 예측

산업정보시스템전공 18102003 이휘영
인공지능응용학과 21102377 이예랑
인공지능응용학과 21102392 최세민

차례

Project overview (what, how, why)

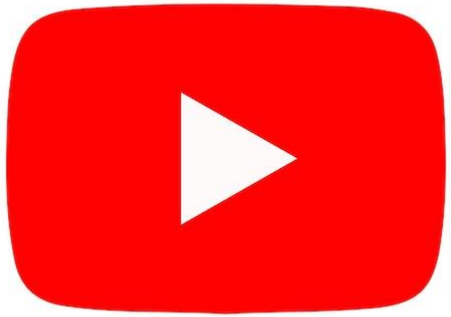

상위에 노출된 댓글의 내용으로
영상의 조회수*를 예측할 수 있을까?

*또는 영상의 흥행 성공 여부

Project overview (what, how, why)

→ **'보다'** 채널의 영상과 댓글을 이용해
동일 채널에 게시된 영상의 조회수를 예측할 수 있는지 확인

Data Collection

youtube_replies.xlsx

	A	B	C	D	E	F	G	H
1	view	194914	319933	608346	98384	402196	150218	232800
2	0	이 교수님	OCN에 켠	보다 멤버	교수님 강	영화 <크리	우와 영상	BODA X 우
3	1	김기범 교	이 네 분 ㄱ	노..	학창시절	크리에이티	제가 이 때	마지막 부
4	2	ㅉㅉㅉㅉㅉ	ㅋㅋ 이건	멤버십분들	역사든 전	말씀하신 (	※ 이 고양	@user-ig
5	3	교수님 목	철학과 문학도 추가시		≤≤유명지	스카이넷드	제가 들어	공부 겁나
6	4	그렇네요 ㅎ	역시 허준형님의 진행		그냥 답글	평소에 과	양자역학적	무지한 우
7	5	더더욱 울	허준님 진		게스트 새	@user-di	인간들이	보다채널	ㅋㅋ 결국 옷
8	6	공항 짓는	ㅇㅇ를 보		@analyst-	역사를보다	ai에 대한	파동의 형	@joshuat
9	7	@RuRang	항상 재밌		이 영상은	≤≤유명지	Oh good	맥락이 없	@joshuat
10	8	울릉도화산	곽민수 소		저랑같은상	BODA 늘	AI에 대한	사실 실험	멍청한 사
11	9	울릉도에서	점점 네분		몇 달 전부	믿고 보는	크리에이티	Blue Box	웅배 나이
12	10	궁금한 내	과학을 보		늘 흥미롭	≤≤유명지	인류 VS A	그럼 블랙	연대화이팅
13	11	전달력이	역사를 보		김범준 교	와 진짜 페	정말, 정영	어렵게 설	≤≤유명지
14	12	멋지세요.	역사를보다		진짜 학창	페르시아가	정영진 매	무슨말인지	과학을 보
15	13	화산에 대	정말 재밌		학창시절에	몽골이 그	와 42분짜	그니까 중	외계인의

(51rows*201columns)

최근 200개 영상의
상위 10개* 댓글 이용
***오류 감안해 50개 수집**

Data Collection

youtube_replies.xlsx

	A	B	C	D	E	F	G	H
1	view	194914	319933	608346	98384	402196	150218	232800
2	0	이 교수님	OCN에 켠	보다 멤버	교수님 강	영화 <크리	우와 영상	BODA X 우
3	1	김기범 교	이 네 분 ㄱ	노..	학창시절	크리에이티	제가 이 때	마지막 부
4	2	ㅉㅉㅉㅉㅉ	ㅋㅋ 이건	멤버십분들	역사든 전	말씀하신	※ 이 고양	@user-ig
5	3	교수님 목	철학과 문학도 추가시		≤≤유명지	스카이넷드	제가 들어	공부 겁나
6	4	그렇네요	역시 허준형님의 진행		그냥 답글	평소에 과	양자역학적	무지한 우
7	5	더더욱 울	허준님 진	게스트 새	@user-di	인간들이	보다채널	ㅋ 결국 옷
8	6	공항 짓는	ㅇㅇ를 보	@analyst-	역사를보다	ai에 대한	파동의 형	@joshuat
9	7	@RuRang	항상 재밌	이 영상은	≤≤유명지	Oh good	맥락이 없	@joshuat
10	8	울릉도화산	곽민수 소	저랑같은상	BODA 늘	AI에 대한	사실 실험	멍청한 사
11	9	울릉도에서	점점 네분	몇 달 전부	믿고 보는	크리에이티	Blue Box	웅배 나이
12	10	궁금한 내	과학을 보	늘 흥미롭	≤≤유명지	인류 VS A	그럼 블랙	연대화이팅
13	11	전달력이	역사를 보	김범준 교	와 진짜 페	정말, 정영	어렵게 설	≤≤유명지
14	12	멋지세요.	역사를보다	진짜 학창	페르시아가	정영진 매	무슨말인지	과학을 보
15	13	화산에 대	정말 재밌	학창시절에	몽골이 그	와 42분짜	그니까 중	외계인의

(51rows*201columns)

조회수

댓글 내용

Data Collection

Selenium, BeautifulSoup 라이브러리 이용

```
from selenium import webdriver
import time
from openpyxl import Workbook
import pandas as pd
from selenium.webdriver.common.keys import Keys
from selenium.webdriver.common.by import By
from bs4 import BeautifulSoup
import requests

import warnings
warnings.filterwarnings('ignore')
```

리스트*(url_list)*의 영상 전부에 대해 실행됨

*유튜브 api 이용 시 발생하는 오류를 고치지 못해 링크는 직접 복사함

```
while True:
    if ii == len(url_list):
        break

    url = url_list[ii]

    driver = webdriver.Chrome("chromedriver.exe")
    driver.get(url)
    driver.implicitly_wait(3)

    # ------------------------------------------------- #
```

```
url_list = ["https://youtu.b
            "https://youtu.be
            "https://youtu.be
            "https://youtu.be
```

Data Collection

```
# ---------------------------------------------------- #

for i in range(5):
    driver.execute_script("window.scrollTo(0,document.documentElement.scrollHeight);")
    time.sleep(2)

time.sleep(2)

# ---------------------------------------------------- #

try:
    driver.find_element_by_css_selector("#dismiss-button").click()
except:
    pass

# ---------------------------------------------------- #

buttons = driver.find_elements(By.CSS_SELECTOR, "#more-replies")
time.sleep(3)

for button in buttons:
    button.click()
    time.sleep(2)

# ---------------------------------------------------- #
```

댓글 확인을 위한 스크롤(5회)

광고 확인 (dismiss)

답글 확인 (more replies)

```
# ---------------------------------------------------- #

while True:
    try:
        more_replies = driver.find_element(By.XPATH, "//span[text()='자세히 보기']")
        if more_replies.is_displayed():
            more_replies.click()
            time.sleep(2)
        else:
            break
    except Exception as e:
        break

time.sleep(3)

# ---------------------------------------------------- #

html_source = driver.page_source
soup = BeautifulSoup(html_source, 'html.parser')

comment_list = soup.select("yt-formatted-string#content-text")

comment_final = []

# ---------------------------------------------------- #
```

댓글 더보기 (자세히 보기) 확인

BeautifulSoup 이용 → html 파싱

```
for i in range(len(comment_list)):
    temp_comment = comment_list[i].text
    temp_comment = temp_comment.replace('\n', '')
    temp_comment = temp_comment.replace('\t', '')
    temp_comment = temp_comment.replace('    ', '')
    comment_final.append(temp_comment)

# ---------------------------------------------------- #

view_count_element = soup.find("span", class_="view-count")
view_count_text = view_count_element.get_text()
view_count = ''.join(filter(str.isdigit, view_count_text))
print("현재 조회수:", view_count)

# ---------------------------------------------------- #

if len(comment_final) > 50:
    del comment_final[50:]
```

공백 제거

조회수 수집

50개 이후의 댓글 제거

```
youtube_pd[view_count] = comment_final

# ---------------------------------------------------- #

print("긁은 영상 수: " + str(youtube_pd.shape[1]))
ii += 1
print("index: " + str(ii))
print("# ---------------------------- #")
```

저장 후 반복

Data Preprocessing

	Views	comments	label
0	194914	이 교수님 정말 재미있게 강의해주시네요... 자주 뵈었음 좋겠습니다.\n김기범 교수...	Good
1	319933	OCN에 켠김에 왕까지에서 허준씨를 처음 봤을때는 이렇게 될 줄은 상상도 못 했습니...	Good
3	98384	교수님 강의를 이렇게 쉽게 들을 수 있다니 행운이고 감사합니다.\n학창시절땐 과학이...	Good
4	402196	영화 <크리에이터> 예매권 이벤트 이 영상에 영화에 대한 기대평 댓글을\n남겨주신...	Good
5	150218	우와 영상 재밌게봤어요! 넘넘 차분하게 전달력 있게 말씀해주시네요.. 하도 슈뢰딩거...	Good
...	...	...	...
195	287723	다양한 천문학 이야기 전할 수 있는 좋은 기회 주신 BODA 분들께 감사드립니다! ...	Good
196	2298575	곧 안전하고 값싼 우주 여행이 실현되길 바랍니다 우주 여행 관련 이야기할 수 있는...	Great
197	362675	오늘도 초대해 주셔서 감사합니다!!!! 자주 놀러와서 축구 이야기 해볼게요!!영상 ...	Good
198	353262	여자를 위해, 여자를 가장 잘 아는 산부인과의사언니 김지연 원장이 개발한 우먼스37...	Good
199	744042	스스로 타는 천체, 스타 개그는 제가 만든 거 아닙니다. 저도ㅠㅠ배운거에요.. \n어...	Great

198 rows × 3 columns

views: 조회수
comments: 댓글 내용
label: 조회수 분류

조회수에 따른 label 부여
600,001 이상: Great
그 외: Good

Data Preprocessing


```
new_df = pd.DataFrame([])
new_df["Views"] = df_trans["view"]
new_df["comments"] = df_trans.iloc[:,1] #df_trans.iloc[:,1:11]
```

```
new_df = pd.DataFrame([])
new_df["Views"] = df_trans["view"]
new_df["comments"] = df_trans.iloc[:,1] #df_trans.iloc[:,1:11]
for i in range(2,NOC+1):
    new_df["comments"] += "\n" + df_trans.iloc[:,i]
#60만회 초과인지 기준으로
new_df["label"] = new_df["Views"].apply(lambda x: 'Great' if int(x)>10e4*6 else 'Good')
#new_df.fillna("\n", inplace=True)
new_df = new_df.dropna()
new_df
```

Data Preprocessing

comments
이 교수님 정말 재미있게 강의해주시네요 자주 뵈었음 좋겠습니다 김기범 교수님 ...
OCN에 켠김에 왕까지에서 허준씨를 처음 봤을때는 이렇게 될 줄은 상상도 못 했습니...
교수님 강의를 이렇게 쉽게 들을 수 있다니 행운이고 감사합니다 학창시절땐 과학이나...
영화 크리에이터 예매권 이벤트 이 영상에 영화에 대한 기대평 댓글을 남겨주신 ...
우와 영상 재밌게봤어요 넘넘 차분하게 전달력 있게 말씀해주시네요 하도 슈뢰딩거고...
...
다양한 천문학 이야기 전할 수 있는 좋은 기회 주신 BODA 분들께 감사드립니다 ...
곧 안전하고 값싼 우주 여행이 실현되길 바랍니다 우주 여행 관련 이야기할 수 있는...
오늘도 초대해 주셔서 감사합니다 자주 놀러와서 축구 이야기 해볼게요 영상 재미있게...
여자를 위해 여자를 가장 잘 아는 산부인과의사언니 김지연 원장이 개발한 우먼스37...
스스로 타는 천체 스타 개그는 제가 만든 거 아닙니다 저도ㅠ배운거에요 어려울...

1) Punctuation 및 특수문자 제거

```
#punctuation 제거, 특수문자 제거, lowercasing
def remove_white_space(text):
    text = re.sub(r'[\t\r\n\f\v]', ' ', str(text))
    return text

def remove_special_char(text):
    text = re.sub('[^ ㄱ-ㅣ가-힣 0-9 a-z A-Z]+', ' ', str(text))
    text.lower()
    return text

new_df.comments = new_df.comments.apply(remove_white_space)
new_df.comments = new_df.comments.apply(remove_special_char)
new_df
```

Data Preprocessing

token_final
[교수, 님, 정말, 재미있다, 강의, 해주다, 자주, 뵈다, 좋다, 김기범, 교수...
[OCN, 켜다, 김, 왕, 까지에, 서다, 허준, 씨, 처음, 보다, 때, 이렇게...
[교수, 님, 강의, 이렇게, 쉬다, 들다, 수, 있다, 행운, 이고, 감사하다, ...
[영화, 크리에이터, 예매, 권, 이벤트, 영상, 영화, 대한, 기, 대, 평, 댓...
[우와, 영상, 재밌다, 보다, 넘다, 넘다, 차분하다, 전달, 력, 있다, 말씀,...
...
[다양하다, 천문학, 이야기, 전, 수, 있다, 좋다, 기회, 주신, BODA, 분...
[곧, 안전하다, 갚씨다, 우주, 여행, 실현, 되다, 바라다, 우주, 여행, 관련...
[오늘, 초대, 주다, 감사하다, 자주, 놀러와, 서, 축구, 이야기, 해보다, 영...
[여자, 위해, 여자, 가장, 자다, 알다, 산부인과, 의사, 언니, 김지연, 원장...
[스스로, 타다, 천체, 스타, 개그, 제, 만들다, 거, 아니다, 저, ㅠㅠ, 배우...

2) Stopwords 제거 및 Tokenize

```
# 불용어 정의
stopwords = ['의','가','이','은','들','는','좀','잘','걍','과','도','를','으로','자','에','와','한','하다','ㅋㅋ']
```

```
okt = Okt()

tokenized_data = []
for sentence in tqdm(new_df['comments']):
    tokenized_sentence = okt.morphs(sentence, norm=True, stem=True)  # 토큰화
    stopwords_removed_sentence = [word for word in tokenized_sentence if not word in stopwords] # 불용어 제거
    tokenized_data.append(stopwords_removed_sentence)
```

tqdm(진행 상황 표시), konlpy(Okt(), 한국어 분석) 이용

Data Preprocessing

단어 임베딩(Word2Vec)

```
embedding_model = Word2Vec(tokenized_df['token_final'],
                           sg = 2, # skip-gram
                           vector_size = 100,
                           window = 2,
                           min_count = 1,
                           workers = 8
                           )

print(embedding_model)
```

```
Word2Vec<vocab=18138, vector_size=100, alpha=0.025>
```

```
embedding_model.wv.save_word2vec_format('week3pj_tokens_eng_w2v')
loaded_model = KeyedVectors.load_word2vec_format('week3pj_tokens_eng_w2v') # 모델 로드

model_result = loaded_model.most_similar("AI")
print(model_result)
```

```
[('방향', 0.9742190837860107), ('군대', 0.9709122180938721), ('과거', 0.9689631462097168), ('입장', 0.9677556753158569), ('생
물', 0.9669126868247986), ('감정', 0.9665217399597168), ('결과', 0.9659112095832825), ('혹시', 0.9650603532791138), ('실험', 0.
9631057381629944), ('경험', 0.9629468321800232)]
```

Data Preprocessing

단어 임베딩(Word2Vec)

```
embedding_model = Word2Vec(tokenized_df['token_final'],
                           sg = 2, # skip-gram
                           vector_size = 100,
                           window = 2,
                           min_count = 1,
                           workers = 8
                           )
```

- **Skip-gram** 이용
- 100차원 벡터
- 인근 2개 단어와의 관계 학습(window=2)
- 등장 단어 전부 학습에 이용

데이터 분할(8:2)

```
rng = RandomState()

tr = df.sample(frac=0.8, random_state=rng)
val = df.loc[~df.index.isin(tr.index)]

tr.to_csv('train.csv', index=False, encoding='utf-8-sig')
val.to_csv('validation.csv', index=False, encoding='utf-8-sig')
```

- Train **8** : Val **2** 로 분할

Model Architecture

TextCNN

```
TextCNN(
  (embed): Embedding(16016, 100)
  (convs): ModuleList(
    (0): Conv2d(1, 10, kernel_size=(3, 100), stride=(1, 1))
    (1): Conv2d(1, 10, kernel_size=(2, 100), stride=(1, 1))
    (2): Conv2d(1, 10, kernel_size=(1, 100), stride=(1, 1))
  )
  (relu): ReLU()
  (dropout): Dropout(p=0.4, inplace=False)
  (fc): Linear(in_features=30, out_features=1, bias=True)
)
```

Model Architecture

TextCNN

```
TextCNN(
  (embed): Embedding(16016, 100)
  (convs): ModuleList(
    (0): Conv2d(1, 10, kernel_size=(3, 100), stride=(1, 1))
    (1): Conv2d(1, 10, kernel_size=(2, 100), stride=(1, 1))
    (2): Conv2d(1, 10, kernel_size=(1, 100), stride=(1, 1))
  )
  (relu): ReLU()
  (dropout): Dropout(p=0.4, inplace=False)
  (fc): Linear(in_features=30, out_features=1, bias=True)
)
```

embedding demension = 100으로 학습된 임베딩 레이어에 입력
→ 100차원 임베딩 벡터로 변환

컨볼루션 레이어에
임베딩 벡터 입력

ReLU 입력 후
max pooling

1차원 텐서 변환 및
fully connected 레이어(깊이 1)에 입력

→ 단일 실수 값 예측

Experimental results

학습 결과는 다음과 같다.

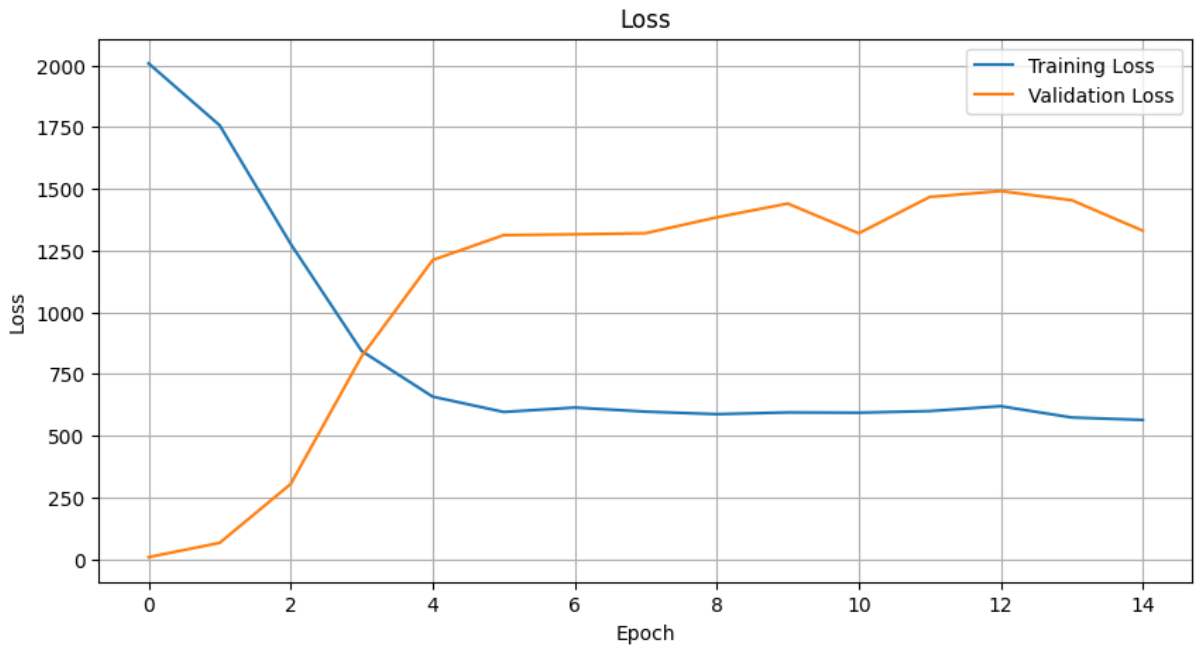

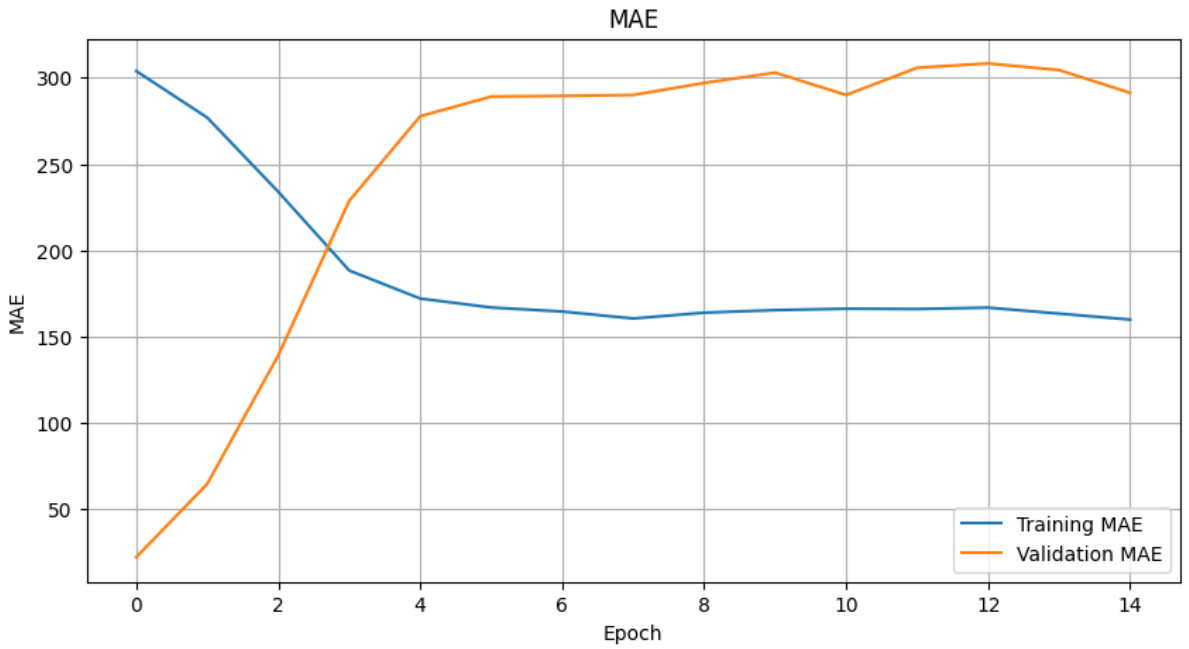

학습이 진행됨에 따라 **train loss와 train MAE가 모두 감소**했지만 **validation set에 대해서는 증가**하였다.

Experimental results

추정되는 원인은 다음과 같다.

- **토큰 임베딩**

학습 데이터 내에 존재하는, 다소 **좁은 범위의 dictionary**를 이용하여 학습되었기 때문에 단어, 또는 토큰의 의미를 충분히 학습하지 못하였을 수 있다. 학습 데이터 뿐 아니라 더욱 **general한 범위**로부터 추출된 많은 양의 문서를 이용해 임베딩 모델을 학습하거나, 이미 그러한 범위에서 학습되어 배포되는 pretrained된 모델을 이용한다면 각 토큰에 대한 더 좋은 representation을 얻을 것으로 기대할 수 있다.

- **아키텍쳐**

CNN은 하나의 윈도우 안에 포함될 수 있는 단어들의 관계만 고려할 수 있다. 따라서 윈도우 사이즈를 초과하는 거리에 있는 단어의 관계나 의미를 파악할 수 없다. 이를 해결하기 위해 윈도우 사이즈를 너무 크게 만든다면 하나의 시퀀스에서 만들 수 있는 값의 개수가 줄어드므로 문장 내에 포함되어 있는 다양한 의미를 추출하는데 제한이 생긴다. 이러한 트레이드 오프 때문에 CNN으로 문장에 대한 representation을 생성할 때 적절한 크기의 커널을 찾는 일은 매우 까다롭다. 따라서 LSTM, GRU와 같은 **RNN 기반 모델**을 사용하거나 **Transformer** 모델을 사용하여 long-term dependency를 해결하는 접근이 더 좋다고 생각한다.

- **학습 과정에서의 Bias**

학습 과정에서 learning rate, batch-size나 epoch수, optimizer, validation set ratio 등 많은 **하이퍼파라미터**가 요구된다.
여러 하이퍼파라미터 조합으로 반복하여 실험하는 과정을 통해 최적의 하이퍼파라미터 셋을 찾아 우리 실험에서의 목적 함수의 글로벌 최적점으로의 수렴을 기대할 수 있다. 또한 train셋과 validation셋 split에서의 bias를 줄이기 위해 여러 폴드로 나누어 실험하는 과정도 고려해볼 수 있다.

감사합니다.

2023 2학기 인공지능시스템 3조

이휘영 · 이예랑 · 최세민